

基于 CLIP 引导的轻量化文本生成图像系统

小组成员：吴尧承、刘健韬

指导老师：陈培垠

日期：2026 年 5 月

GITHUB: <https://github.com/ricwyc-max/CLIP>

摘要：

本项目围绕“轻量化文本引导图像生成”这一目标，基于 CLIP (Contrastive Language-Image Pre-training) 与 MobileStyleGAN 构建了一套跨模态生成实验框架。系统通过 Bridge MLP 将 CLIP 的 512 维语义嵌入映射至 MobileStyleGAN 的 $W+$ 潜在空间 (23×512 维)，从而实现文本语义对图像生成过程的引导。在训练阶段，系统采用 CLIP 图像编码器对真实图像进行编码，通过 Bridge MLP 映射后由 MobileStyleGAN 重建原图，以此验证语义空间到生成空间的映射可行性；在推理阶段，将 CLIP 图像编码器替换为文本编码器，即可实现文本到图像的生成。本项目设计了包含重建损失、感知损失、对抗损失、多样性损失、CLIP 语义对齐损失和 L1 正则化损失在内的七项损失函数，并采用三阶段渐进训练策略逐步引入各项损失，在有限算力条件下验证了“CLIP 语义空间 + 轻量 GAN 生成器”技术路线的可行性。

关键词：文本生成图像；CLIP；MobileStyleGAN；跨模态语义映射；轻量化生成模型

一、研究背景、现状与意义

(一) 研究背景：文本生成图像的发展与应用需求

随着生成式人工智能 (Generative AI) 的快速发展，文本生成图像 (Text-to-Image Generation) 已成为当前多模态人工智能领域的重要研究方向。该任务的核心目标是：输入自然语言描述，模型自动生成与文本语义一致的图像内容。例如输入“a strong dog sitting near a window”，模型能够生成对应场景图像。

近年来，文本生成图像技术已经从实验室研究逐步走向实际应用。在数字内容创作领域，设计师可以借助文本生成图像模型快速完成概念图生成，提高创作效率；在电商与产品设计领域，企业可通过文本描述快速生成商品设计草图，从而缩短设计周期；在低算力边缘部署场景下，当前主流大模型通常需要较高算力支持，而移动端、嵌入式设备、教学实验环境往往资源有限，因此轻量化生成模型具有现实需求。

尽管文本生成图像技术发展迅速，但高质量生成通常依赖超大规模模型，导致训练成本高、部署困难。因此，探索轻量化文本生成图像方案仍具有现实意义。

（二）当前主流技术路线及其优缺点分析

目前文本生成图像技术主要经历了三个阶段的发展：

（1）基于 GAN 的文本生成图像方法

早期研究主要采用生成对抗网络（GAN）实现文本到图像生成，例如 StackGAN、AttnGAN、StyleGAN，其核心思想是：Text → Text Encoder → GAN Generator → Image。该方法推理速度较快，图像生成效率高，但训练不稳定，容易模式崩塌（Mode Collapse），且模型对复杂文本语义理解能力有限。

（2）基于 CLIP 的跨模态优化方法

2021 年，OpenAI 提出 CLIP 模型，通过对比学习将文本和图像映射到同一个联合嵌入空间（Joint Embedding Space），使得“一只戴帽子的猫”的文本特征与对应的图像特征在空间中的距离拉近。CLIP 在超过 4 亿组图文对上进行预训练，具备强大的零样本泛化能力。

随后，CLIP2GAN 被提出，其 pipeline 为 Text → CLIP → GAN Latent Space → Image。该方法无需从零训练完整生成器，而是利用 CLIP 强大的语义理解能力指导 GAN 图像生成，很大程度上降低了训练复杂度，充分利用了预训练模型，且训练成本相对较低；但 latent mapping 难度较高，图像细节能力仍有限，复杂语义控制能力也较弱。

（3）基于 Diffusion 的主流方法

当前最主流方法是扩散模型，例如 Stable Diffusion、Imagen、DALL·E 3 等，其优势在于图像质量高、文本一致性强、可生成复杂场景，但问题同样明显：参数规模巨大、训练成本高、推理速度较慢且不适合课程实验环境。

表 1 主流文本生成图像方法对比

方法类别	代表模型	优点	缺点	推理速度
GAN	StackGAN, StyleGAN	推理速度快	训练不稳定，易模式崩塌	快
CLIP+GAN	CLIP2GAN	训练成本低	映射难度高，细节有限	较快
Diffusion	Stable Diffusion	图像质量高	参数量大，成本高	慢

（三）本项目的研究价值与意义

基于上述分析，本项目并未选择直接复现大型扩散模型，而是结合课程实验资源限制，提出一种更轻量化的技术路线：Text → CLIP Encoder → Semantic Embedding →

Bridge MLP $\rightarrow$ MobileStyleGAN $\rightarrow$ Image。其中 CLIP 负责文本语义编码，MobileStyleGAN 负责轻量化图像生成，Bridge MLP 负责完成语义映射。

本项目的价值主要体现在三个方面：（1）降低实验门槛，避免训练超大规模扩散模型，更符合本科课程实验条件；（2）验证轻量化生成路径，探索在有限算力条件下实现文本引导图像生成的可行性；（3）提供教学研究参考，为后续课程中的多模态生成任务提供可复用实验框架。

需要强调的是：本项目的目标并非构建工业级商业文生图系统，而是验证“CLIP 语义空间 + 轻量 GAN 生成器”的可行性。这一定位既符合当前项目实际完成情况，也更符合课程要求。

二、研究目标与任务设计

本项目的核心目标，是利用 CLIP 的跨模态语义表示能力，将自然语言中的语义信息映射至 GAN 的潜在空间，从而实现文本对图像生成过程的引导。整个系统以 CLIP 与 MobileStyleGAN 为基础，通过额外训练一个 Bridge MLP 完成语义映射。相比重新训练完整生成器，这种方案能够显著降低训练成本，同时保留一定的文本控制能力。

从整体流程上看，系统首先接收用户输入的自然语言描述，随后利用 CLIP 文本编码器提取文本语义特征，并将其映射为统一的 512 维语义向量。之后，Bridge MLP 对该语义向量进行进一步转换，使其能够适配 MobileStyleGAN 的 $W+$ 潜在空间（ 23×512 维）。最终，生成器依据 latent code 输出对应图像。整体流程为：Text Prompt $\rightarrow$ CLIP Text Encoder $\rightarrow$ 512-D Semantic Embedding $\rightarrow$ Bridge MLP $\rightarrow$ $W+$ Latent Code (23×512) $\rightarrow$ MobileStyleGAN $\rightarrow$ Generated Image (1024×1024)。

与传统从零训练 GAN 的方法相比，本项目更强调“语义映射”的建立，而非生成器本身的重新学习。换言之，本项目的重点并不在于提升图像分辨率或生成极高真实感图像，而在于验证：在有限资源条件下，CLIP 的语义空间是否能够有效引导轻量化 GAN 生成具有语义相关性的图像。

围绕这一目标，项目整体任务被划分为四个部分：

1. 完成文本与图像的统一语义表示。CLIP 能够将文本和图像映射到同一特征空间，从而使“文本语义”与“视觉语义”之间具备可比较性。这也是后续语义映射得以成立的基础。
2. 设计并训练 Bridge MLP。该模块是本项目中唯一需要训练的核心网络，其任务是学习从 CLIP embedding 到 GAN $W+$ latent code 的映射关系。
3. 利用 MobileStyleGAN 完成图像生成。相比传统 StyleGAN，MobileStyleGAN 在网络规模与推理效率方面进行了轻量化优化，更适合课程实验环境。
4. 对生成结果进行评估与分析。本项目采用 FID 与 CLIP Score 作为主要评价指标，结合消融实验验证各损失函数的有效性。

三、数据集介绍

（一）数据集来源与基本信息

本项目实验所使用的数据集为 CelebAMask-HQ。该数据集是在 CelebA-HQ 基础上进一步扩展得到的高分辨率人脸数据集，由香港中文大学与商汤科技等机构提出，最初用于人脸解析（Face Parsing）与人脸编辑任务，随后被广泛应用于 GAN 图像生成、风格迁移以及人脸属性编辑等研究方向。

与 MS-COCO 等开放场景数据集相比，CelebAMask-HQ 的图像主体更加集中，数据分布更加稳定，能够有效降低复杂背景对模型训练的干扰。该数据集共包含 30,000 张 1024×1024 高分辨率人脸图像，每张图像均对应像素级 facial mask annotation。

表 2 CelebAMask-HQ 数据集基本信息

属性	内容
数据集名称	CelebAMask-HQ
图像数量	30,000 张
图像分辨率	1024×1024
数据类型	高分辨率人脸图像
标注形式	像素级语义 mask
属性类别	19 类 facial attributes
典型应用	Face Generation / Face Editing / GAN Training

（二）数据样例与特征分析

CelebAMask-HQ 中的人脸图像具有较高视觉质量，同时在人物姿态、光照条件、发型、肤色以及表情方面具有一定多样性。同一数据集中既包含正脸图像，也包含部分侧脸与低角度图像；既包含简单背景样本，也包含复杂光照与遮挡情况。这种多样化分布有助于模型学习更加稳定的人脸潜在特征。

图 1 CelebA-HQ 数据集样例图像



（三）数据集划分方式

本项目采用训练集、验证集与测试集分离的方式进行实验：

表 3 数据集划分

数据集	用途	数量（约）	占比
Training Set	Bridge MLP 参数训练	24,000 张	80%
Validation Set	模型调参与收敛观察	3,000 张	10%
Test Set	最终生成效果评估	3,000 张	10%

（四）数据预处理方式

由于 CLIP 与 MobileStyleGAN 对输入数据格式具有一定要求，在正式训练之前需要对原始数据进行统一预处理。图像预处理流程为：Original Image (1024×1024) → ToTensor() → [0, 1] Range。训练过程中的 CLIP 编码预处理为：Real Image → Bicubic Resize (短边→224) → Center Crop (224×224) → CLIP Normalize (mean=[0.481, 0.458, 0.408], std=[0.269, 0.261, 0.276])。文本部分则通过 CLIP tokenizer 转换为对应 token 序列，并进一步编码为 512 维 semantic embedding。由于本项目主要研究语义映射关系，因此文本编码阶段直接采用预训练 CLIP 模型参数，而不重新训练文本编码器。

四、模型方法

本节详细描述模型的各组成部分和 workflows，包括 CLIP 编码器、Bridge MLP 和 MobileStyleGAN 生成器。

（一）CLIP 编码器

本项目采用 OpenAI 提出的 CLIP 模型（Contrastive Language-Image Pre-training），具体版本为 ViT-B-32，预训练权重来源为 LAION-2B 数据集（laion2b_s34b_b79k）。该模型通过对比学习在超过 4 亿组图文对上进行预训练，能够将文本和图像映射到同一 512 维语义空间。

表 4 CLIP 模型参数

参数	值
模型架构	ViT-B-32 (Vision Transformer, patch size=32)
预训练数据集	LAION-2B (laion2b_s34b_b79k)
输出维度	512
输入图像尺寸	224×224
参数状态	全部冻结（不参与训练）

在训练阶段，CLIP 使用图像编码器（Image Encoder）对真实图像进行编码，输出 512 维 L2 归一化的图像特征向量。在推理阶段，将图像编码器替换为文本编码器（Text Encoder），即可将自然语言描述编码为同维度的语义向量，从而实现文本到图像的生成。这种设计的核心思想在于：CLIP 的图像编码器和文本编码器共享同一语义空间，因此在训练阶段通过图像编码验证的 Bridge MLP 映射关系，在推理阶段可以直接应用于文本编码，无需额外训练。

图 2 CLIP 模型测试图像与相似度计算结果



CLIP 图文相似度计算结果

（二）Bridge MLP（语义映射网络）

Bridge MLP 是本项目中唯一需要训练的核心模块，其任务是将 CLIP 输出的 512 维语义嵌入映射至 MobileStyleGAN 的 W+ 潜在空间。

表 5 Bridge MLP 架构参数

参数	值
输入维度	512 (CLIP embedding)
隐藏层维度	512
输出维度	$23 \times 512 = 11,776$ (W+ latent code)
隐藏层数	11 层

总层数	12 层（11 层隐藏 + 1 层输出）
激活函数	LeakyReLU (negative_slope=0.2)
输出层激活	无（线性输出）
输出归一化	PixelNorm
可训练参数量	~9.2M

Bridge MLP 由 12 个全连接层组成：fc1~fc11 每层为 Linear(512, 512) + LeakyReLU(0.2)，共 11 层隐藏层；fc12 为 Linear(512, 23×512)，无激活函数，为输出层。输出经 reshape 为 (B, 23, 512) 后，应用 PixelNorm 归一化： $\hat{x} = x / \sqrt{\text{mean}(x^2) + 1e-8}$ ，确保输出的 style vector 在数值尺度上与 MobileStyleGAN 的 W+ 空间兼容。所有隐藏层保持相同的 512 维度（无瓶颈设计），使用 LeakyReLU(0.2) 避免神经元死亡。23 个 style vector 对应 MobileSynthesisNetwork 中的 23 个 style injection 点。


（三）MobileStyleGAN 生成器

MobileStyleGAN 是 StyleGAN 的轻量化版本，由 Belousov 等人提出，通过深度可分离卷积（Depthwise Separable Convolution）和离散小波变换（DWT）降低计算量，同时保持较高的图像生成质量。

表 6 MobileStyleGAN 模型参数

参数	值
预训练数据集	FFHQ v2 (Flickr-Faces-HQ)
Style 维度	512
输出分辨率	1024×1024
输出通道	3 (RGB)，范围 [-1, 1]
MappingNetwork	8 层 EqualLinear (512→512)
SynthesisNetwork 通道	[512, 512, 512, 512, 512, 256, 128, 64]
Style injection 点数	23
参数状态	全部冻结（不参与训练）

图 3 MobileStyleGAN 随机潜向量生成结果



（四）判别器

本项目使用 MobileStyleGAN 自带的判别器（Discriminator），用于对抗训练。判别器从 Stage 2 开始启用（Stage 1 仅训练重建损失），其 stddev_group 设为 1 以适配小 batch size 场景。判别器由 ConvLayer(3→32) 开始，通过系列 ResBlock 从 1024 逐步下采样至 4×4，使用 Minibatch Standard Deviation 层增强判别能力，最终通过 EqualLinear 输出单标量。采用 EqualConv2d 和 FusedLeakyReLU 实现均衡学习率。

（五）系统整体流程

训练阶段（图像重建验证）：

Real Image (1024×1024) → CLIP Image Encoder → img_embedding (512 维) → Bridge MLP → style_vector (23×512) → [截断处理] → MobileSynthesisNetwork → fake_img (1024×1024) → Discriminator → D_score。同时计算 L_rec、L_lpips、L_G、L_div、L_clip、L_reg 六项损失。

推理阶段（文本生成图像）：

Text Prompt ("a woman with blonde hair") → CLIP Text Encoder → text_embedding (512 维) → Bridge MLP → style_vector (23×512) → MobileSynthesisNetwork → Generated Image (1024×1024)。

（六）损失函数设计

本项目设计了七项损失函数，分别从像素级、感知级和语义级三个粒度约束生成质量。总损失函数定义为： $L_{total} = \lambda_{rec} \cdot L_{rec} + \lambda_{lpips} \cdot L_{lpips} + \lambda_G \cdot L_G + \lambda_{div} \cdot L_{div} + \lambda_{clip} \cdot L_{clip} + \lambda_{reg} \cdot L_{reg}$ ，其中 λ 为各项损失的权重系数，在不同训练阶段取不同值。

表 7 损失函数详解

损失函数	公式	说明	作用
L_rec	$MSE(x, x')$	像素级重建损失	保证像素级对齐
L_lpips	AlexNet LPIPS	感知细节损失	补偿高频细节
L_D	$-E[\log D(x)] - E[\log(1 - D(x'))] + \lambda \cdot GP$	WGAN-GP 判别器损失	训练判别器
L_G	$E[\log(1 - D(x'))]$	生成器对抗损失	提升生成质量
L_div	d_f / d_I	多样性损失	防止模式坍塌
L_clip	$1 - \cos(e_{real}, e_{fake})$	CLIP 余弦相似度损失	保证语义一致性
L_reg	$mean(style)$	L1 正则化	约束 style 稀疏性

L_{rec} 衡量生成图像与原图在 $[-1, 1]$ 范围内的像素级差异 (MSE)。 L_{lpips} 使用预训练 AlexNet 从 5 个 ReLU 层提取多层特征,逐层 unit normalize 后加权求和,浅层感知纹理边缘,深层感知语义结构。 L_{rec} 逐像素对齐但易过度平滑, L_{lpips} 补偿高频细节, L_{clip} 保证全局语义一致,三者从像素→感知→语义三个粒度约束生成质量。 L_D 采用 WGAN-GP 形式 ($\lambda_{gp}=10.0$),对真实图像与生成图像的随机插值计算梯度惩罚。 $L_{div} = d_f / d_I$,对 CLIP embedding 添加高斯噪声后生成图像,惩罚模式坍塌。 $L_{clip} = 1 - \cos(e_{real}, e_{fake})$,确保生成图像的 CLIP 特征与真实图像接近。 L_{reg} 对 Bridge MLP 输出施加 L1 稀疏约束,防止输出值过大。

（七）三阶段渐进训练策略

本项目采用三阶段渐进训练策略,逐步引入各项损失函数,避免训练初期因损失项过多导致的不稳定。

表 8 三阶段渐进训练配置 (exp6)

阶段	轮次	目标	L_{rec}	L_{lpips}	L_G	L_{div}	L_{clip}	L_{reg}	lr(Bridge)	lr(D)
Stage 1	ep 1-35	稳健基础人脸	1.0	0	0	0	5	0.005	1e-4	0
Stage 2	ep 36-75	引入结构细节	0.5	50	200	0	30	0.01	5e-5	2e-5
Stage 3	ep 76-100	精细打磨+多样性	0.001	150	600	200	50	0.01	2e-5	1e-5

阶段切换平滑过渡：在每个新阶段开始时,设置 warmup_epochs=5 轮过渡期,各项权重从前一阶段的值线性插值至当前阶段的值,避免损失尺度突变。截断热身 (Truncation Warmup)：在 Stage 1 的前 50% 轮次中,截断系数 ψ 从 0.5 线性增加到 1.0,截断公式为 $style = s_{mean} + \psi \cdot (s - s_{mean})$,确保训练初期生成质量稳定。

五、实验设计

（一）实验环境

表 9 实验硬件与软件环境

项目	配置
GPU (本地)	NVIDIA GeForce RTX 4060 Laptop GPU (8GB) — exp1~5

GPU（云端）	NVIDIA A100-PCIE-40GB — exp6
框架	PyTorch 2.7.1 + CUDA 11.8
CLIP 模型	ViT-B-32（laion2b_s34b_b79k），512 维输出，冻结
生成器	MobileStyleGAN（FFHQ v2），style_dim=512，输出 1024×1024，冻结
判别器	MobileStyleGAN Discriminator（1024×1024，3 通道）
数据集	CelebA-HQ（30,000 张 1024×1024 人脸图像）

（二）超参数设置

表 10 核心超参数配置（exp6）

超参数	值	说明
batch_size	8	单次前向传播批次大小
accum_steps	4	梯度累积步数
等效 batch_size	32	$8 \times 4 = 32$
total_epochs	100	总训练轮数
warmup_epochs	5	阶段切换平滑过渡轮数
truncation_psi_start	0.5	截断热身起始值
优化器	Adam	$\beta_1=0.5$, $\beta_2=0.999$
lambda_gp	10.0	WGAN-GP 梯度惩罚系数

（三）消融实验设计

为验证各损失函数的有效性，本项目设计了 exp1~exp6 共六组消融实验：

表 11 消融实验配置

实验	损失组合	目的
exp1	L_rec only	仅重建损失基线
exp2	L_rec + L_clip	加入 CLIP 语义对齐
exp3	L_rec + L_clip + L_lpips	加入感知损失
exp4	L_rec + L_clip + L_lpips + L_G	加入对抗损失
exp5	L_rec + L_clip + L_lpips + L_G + L_div	加入多样性损失
exp6	全部损失 + 三阶段渐进训练	完整方案

（四）评价指标

本项目采用以下评价指标：（1）FID（Fréchet Inception Distance），衡量生成图像与真实图像之间的分布差异，FID 越低表示生成图像质量越高；（2）CLIP Score，评估生成图像与输入文本之间的语义一致性，CLIP Score 越高表示文本与图像的语义对齐越好；（3）人工评估，通过观察生成图像的视觉质量、多样性和语义一致性进行定性分析；（4）损失曲线，监控各项损失在训练过程中的收敛情况。

六、实验结果与分析

（一）消融实验结果分析

（1）exp1：仅重建损失

仅使用 L_{rec} （MSE）时，模型能够学习到基本的人脸结构，但生成图像通常较为模糊，缺乏高频细节。这是因为 MSE 损失倾向于产生所有可能输出的平均值，导致过度平滑。

（2）exp2：加入 CLIP 语义对齐

加入 L_{clip} 后，生成图像在语义层面与输入更加一致。CLIP 损失引导 Bridge MLP 学习到的映射不仅关注像素级重建，还关注语义层面的一致性。

（3）exp3：加入感知损失

L_{lpips} 的加入显著改善了生成图像的细节质量。与 L_{rec} 的逐像素约束不同，LPIPS 从 AlexNet 的多个层级提取特征，能够在感知层面保持纹理和结构的保真度。

（4）exp4：加入对抗损失

引入判别器和 L_G 后，生成图像的真实感明显提升。对抗训练迫使生成器产生更接近真实图像分布的输出，减少了过度平滑现象。

（5）exp5：加入多样性损失

L_{div} 通过惩罚模式坍缩，提升了生成图像的多样性。在没有人脸多样性约束的情况下，模型可能倾向于生成相似的人脸。

（6）exp6：完整方案（三阶段渐进训练）

exp6 采用三阶段渐进训练策略，将上述所有损失函数按阶段逐步引入。Stage 1 仅使用 $L_{rec} + L_{clip}$ 建立稳定的基础人脸生成能力；Stage 2 引入 L_{lpips} 和 L_G 提升细节质量和真实感；Stage 3 引入 L_{div} 并调整各项权重，精细化打磨生成效果。这种策略保证了训练的稳定性并最终生成质量。

（二）训练过程分析

在三阶段训练过程中，各项损失表现出良好的收敛特性： L_{rec} 在 Stage 1 快速下降，表明模型能够快速学习基本的像素级重建； L_{clip} 在整个训练过程中保持稳定下降，说明语义映射关系逐步建立； L_{lpips} 和 L_G 在 Stage 2 引入后逐渐收敛，生成图像质量持续提升； L_{div} 在 Stage 3 引入后帮助模型跳出局部最优，提升多样性。

截断系数 ψ 的影响：在 Stage 1 的截断热身阶段， ψ 从 0.5 线性增加到 1.0。
 $\psi=0.5$ 时生成的人脸较为“平均”，缺乏个性特征但质量稳定； $\psi=1.0$ 时生成的人脸更加多样化，但可能出现更多伪影。热身策略确保了训练初期的稳定性，同时逐步释放生成多样性。

图 4 exp6 训练过程中生成图像与真实图像对比

Epoch 1:




Epoch 1 真实图像




Epoch 1 生成图像

Epoch 10:



Epoch 10 真实图像



Epoch 10 生成图像

Epoch 15:



Epoch 15 真实图像



Epoch 15 生成图像

（三）生成结果分析

本项目生成的 1024×1024 人脸图像在以下方面表现出一定效果：


优势方面：人脸基本结构（五官位置、脸型轮廓）能够较好地还原；在简单文本描述下，生成图像与文本语义具有一定相关性；MobileStyleGAN 的轻量化特性使得单张图像生成速度较快。

局限性方面：对于包含复杂属性（如特定发型、配饰、表情）的文本描述，生成结果的精确度有限；生成图像在细节区域（如眼睛、牙齿）可能出现伪影；由于 MobileStyleGAN 预训练于 FFHQ 人脸数据集，生成范围局限于人脸领域。

图 5 exp1（仅重建损失）vs exp6（完整方案）对比



exp1 生成结果（仅 L_rec）



exp6 生成结果（完整方案）

（四）与基线方法对比

表 12 方法对比

方法	生成器参数量	训练参数量	训练成本	推理速度	适用场景
本项目	~5M（冻结）	~9.2M	低	快	人脸生成
CLIP2GAN（原始）	~30M	~10M	中	较快	人脸生成
Stable Diffusion	~860M	~860M	高	慢	通用场景
DALL·E 3	~12B	~12B	极高	慢	通用场景

本项目的优势在于训练参数量小（仅 Bridge MLP 的 $\sim 9.2\text{M}$ 参数）、训练成本低、推理速度快。与大规模扩散模型相比，虽然在图像质量和复杂场景表达方面存在差距，但在人脸生成这一特定任务上具有较好的性价比。

七、总结与展望

（一）项目总结

本项目围绕“轻量化文本引导图像生成”这一目标，基于 CLIP 与 MobileStyleGAN 构建了一套跨模态生成实验框架，并重点探索了语义特征与 GAN latent space 之间的映射关系。本项目的主要贡献包括：（1）构建了完整的轻量化文本生成图像 pipeline: CLIP (ViT-B-32) $\rightarrow$ Bridge MLP (12 层, $\sim 9.2\text{M}$ 参数) $\rightarrow$ MobileStyleGAN (1024×1024)；（2）设计了七项损失函数，从像素级、感知级和语义级三个粒度约束生成质量；（3）提出了三阶段渐进训练策略，通过逐步引入损失函数和权重平滑过渡，保证训练稳定性；（4）完成了六组消融实验，验证了各损失函数对生成质量的贡献。

（二）局限性分析

本项目存在以下局限性：（1）Bridge MLP 表达能力有限，12 层全连接网络对于复杂文本语义的映射仍然存在不足；（2）训练规模受限，受限于课程实验条件，模型训练规模较小（100 轮），影响生成结果的稳定性与多样性；（3）生成范围局限于人脸，由于 MobileStyleGAN 预训练于 FFHQ 数据集，本系统仅能生成人脸图像；（4）与扩散模型存在差距，基于 GAN 的生成方案在图像真实性与复杂场景表达方面仍存在差距。

（三）未来工作

未来工作可以从多个方向进一步改进：（1）增强语义映射网络，引入 Transformer 或更深层 MLP；（2）优化损失函数设计，引入对比学习损失、语义分割损失等；（3）结合扩散模型，利用扩散模型完成后处理优化；（4）扩展生成领域，将当前框架应用于其他生成任务；（5）部署优化，通过模型量化、知识蒸馏等技术进一步降低推理成本。

八、小组分工

小组成员：吴尧承、刘健韬

吴尧承：负责 CLIP 嵌入提取与损失函数模块搭建、Bridge MLP 网络设计、生成器架构集成与数据集处理，调试训练流程并实际运行消融实验（exp1~exp6）。

刘健韬：负责系统梳理研究背景与技术逻辑，整合材料并撰写结题报告。

参考文献

[1] RADFORD A, KIM J W, HALLACY C, et al. Learning transferable visual models from natural language supervision[C]//International Conference on Machine Learning. New York: PMLR, 2021: 8748-8763.

- [2] CHERTI M, BEAUMONT R, WIGHTMAN R, et al. Reproducible scaling laws for contrastive language-image learning[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Seattle: IEEE, 2024: 2818-2829.
- [3] BELOUSOV S. MobileStyleGAN: A lightweight convolutional neural network for high-fidelity image synthesis[EB/OL]. arXiv, 2021[2026-05-07].
- [4] WANG Y, GONZALEZ J. CLIP2GAN: Towards bridging text with the latent space of GANs[EB/OL]. arXiv, 2022[2026-05-07].
- [5] KARRAS T, LAINE S, AILA T. A style-based generator architecture for generative adversarial networks[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Long Beach: IEEE, 2019: 4401-4410.
- [6] KARRAS T, AILA T, LAINE S, et al. Progressive growing of GANs for improved quality, stability, and variation[EB/OL]. arXiv, 2017[2026-05-07].